

# L'emivita del calcolo: un modello di decadimento della capacità nazionale di IA in regime di recisione delle forniture

Kevin Escoda<sup>1</sup>

<sup>1</sup> diShine · Data, AI & Automation, Milano, Italia · kevin@dishine.it

ORCID 0009-0009-7368-8129

8 agosto 2026

DOI 10.5281/zenodo.21866487

## ABSTRACT

I controlli sulle esportazioni di hardware per l'intelligenza artificiale sono giustificati da un'affermazione temporale implicita: limitare l'accesso agli acceleratori avanzati farebbe *guadagnare tempo*. L'ampiezza di questo intervallo non è mai stata stimata. La letteratura di misurazione tratta la capacità nazionale di IA come uno *stock*: undici indici pubblici classificano le giurisdizioni per calcolo installato, talento e infrastrutture, e nessuno modella che cosa accada a quello stock una volta interrotto il riapprovvigionamento. La ricerca sull'affidabilità, all'opposto, misura il guasto degli acceleratori sotto l'ipotesi esplicita di rifornimento continuo. Questo articolo congiunge i due filoni. Modelliamo un parco installato di acceleratori come una flotta di capitale deperibile, soggetta a guasto hardware, obsolescenza rispetto a una frontiera di capacità mobile, recupero parziale di componenti e sostituzione interna limitata, e ne deriviamo tre grandezze riportabili: l'emivita del calcolo  $T_{1/2}$ , il tempo di uscita dalla frontiera  $T_f$  e la soglia di sovranità  $C_\infty$ . I tassi di guasto sono derivati da telemetria pubblicata di grandi cluster (tasso annuo di guasto di package pari al 9,08%, validato per via incrociata contro una stima indipendente entro l'1,4%). Otteniamo un risultato analitico: il recupero di componenti assorbe il flusso di guasti solo fino a una resa critica di cannibalizzazione  $\kappa^* = \lambda L$ , pari a 0,38 con i parametri centrali, oltre la quale ulteriore capacità di recupero non produce alcun beneficio e il decadimento è governato dalla sola obsolescenza, mentre al di sotto i guasti non riparati accelerano il declino fino al 40%. Poiché la memoria ad alta banda è integrata nello stesso package del die e nessuno dei due è sostituibile sul campo, l'intervallo plausibile per gli acceleratori è a cavallo di questa soglia. Applicando il modello a tre giurisdizioni, collochiamo l'uscita dalla frontiera fra 25 e 49 mesi, governata da  $T_f \approx T_{dbl} \log_2(C_0/\theta F_0)$ : il parco installato compra tempo solo in modo **logaritmico**, sicché un ordine di grandezza in più di calcolo compra circa 17 mesi ulteriori, e il decadimento hardware pesa solo per il 13-14% dell'intervallo. Le soglie di sovranità mediane sono il 31,1% per gli Stati Uniti, il 53,4% per la Cina, il cui intervallo al 90% spazia però dal 22,1% al 155,7%, sicché l'autosufficienza cinese è, sui dati pubblici attuali, genuinamente indeterminata, e il 3,1% per l'Unione Europea. L'analisi di sensibilità mostra che il ritmo di avanzamento della frontiera domina l'attrito hardware di sette volte. L'implicazione di policy è che la recisione non deve distruggere il calcolo dell'avversario: dove anche l'accesso remoto è interdetto, basta congelarlo mentre la frontiera avanza.

**Parole chiave** governance del calcolo; controlli sulle esportazioni; sovranità tecnologica; catene di fornitura dei semiconduttori; interdipendenza armata; politiche dell'IA; analisi di sopravvivenza

**JEL** F51, F52, L63, O33, O38 · **ACM CCS** Social and professional topics → Computing and business; Hardware → Reliability

## 1 Introduzione

Ogni argomento a favore del controllo delle esportazioni di hardware per l'intelligenza artificiale poggia su un'affermazione relativa al tempo. Limitare l'accesso di un avversario agli acceleratori avanzati *farebbe guadagnare* qualcosa: un vantaggio, una finestra, un ritardo prima della parità di capacità. L'affermazione è temporale, quantitativa e, per quanto abbiamo potuto accertare, non quantificata. Nessun lavoro pubblicato indica per quanto tempo una giurisdizione recisa dalla catena globale di fornitura degli acceleratori potrebbe sostenere il parco di calcolo che già possiede.

Non è per carenza di misurazione. La capacità nazionale di intelligenza artificiale è oggi una delle grandezze più intensamente indicizzate delle politiche tecnologiche. Almeno undici strumenti pubblici classificano le giurisdizioni secondo qualche combinazione di calcolo installato, energia, talento, produzione di modelli e capacità di governance. Differiscono per costruzione e per trasparenza, ma condividono una proprietà strutturale: ciascuno è una **fotografia delle dotazioni**. Rispondono alla domanda *che cosa possiede un paese?* Nessuno risponde alla domanda *che cosa conserverebbe?*

La distinzione conta perché il calcolo installato non è una riserva. È una flotta di capitale con un tasso di guasto misurabile, una vita economica controversa, una dipendenza da una fornitura di memoria concentrata a parte, e una capacità che si definisce rispetto a una frontiera che non sta ferma. Una riserva aurea non si corrode; un parco di acceleratori sì. Trattare le due cose allo stesso modo è l'errore di modellazione che questo articolo intende correggere.

La letteratura sull'affidabilità ha misurato con precisione il tasso di corrosione, ma sotto un'ipotesi che ne annulla l'uso in questo contesto. La telemetria dei grandi cluster fornisce statistiche di guasto ben caratterizzate, e l'analisi più autorevole sulla questione se tali guasti limitino la scalabilità conclude di no, dichiarando però esplicitamente di assumere che i nodi di ricambio restino acquistabili e di non trattare le interruzioni della catena di fornitura né le situazioni in cui i chip di sostituzione non possano essere procurati. È precisamente questa l'ipotesi che la recisione rimuove. Rimuoverla è il contributo del presente lavoro.

### 1.1 Contributo

1. **Un modello di decadimento del calcolo installato in regime di recisione.** Trattiamo un parco nazionale di acceleratori come una flotta deperibile soggetta a guasto, obsolescenza, recupero parziale di componenti e sostituzione interna limitata, integrandola mensilmente. I parametri di guasto sono derivati da telemetria pubblicata anziché assunti, e validati per via incrociata contro una stima indipendente.
2. **Tre grandezze riportabili.** L'emivita del calcolo  $T_{1/2}$ , il tempo di uscita dalla frontiera  $T_f$  e la soglia di sovranità  $C_\infty$ , la capacità che una giurisdizione conserva asintoticamente con la sola produzione interna.  $C_\infty$  è, sosteniamo, la grandezza che il termine *sovranità* ha indicato finora senza mai riceverne un numero.
3. **Una soglia analitica.** Il recupero di componenti sostiene un parco installato solo al di sopra di una resa critica di cannibalizzazione  $\kappa^* = \lambda L$ . È una proprietà dell'hardware, non delle politiche, e separa due regimi di recisione qualitativamente diversi.
4. **Un risultato negativo riportato per intero.** Abbiamo tentato di calibrare il modello sull'unica recisione osservata di una flotta di capitale comparabile, l'aviazione civile russa dopo il febbraio 2022, e la calibrazione fallisce. Riportiamo il fallimento, ne diagnosticiamo la causa e spieghiamo perché esso vincola l'analogia e non il modello.

Deliberatamente non proponiamo un ulteriore indice. Il campo ne conta undici, e un undicesimo e mezzo non sarebbe né originale né utile. Gli indici esistenti entrano in questo articolo come input e come letteratura di riferimento, non come concorrenti.

## 2 Letteratura di riferimento

### 2.1 Misurare la capacità tecnologica nazionale

Gli indici compositi di capacità tecnologica sono numerosi e metodologicamente maturi. Il Machinepower Index (2026) valuta venticinque giurisdizioni su dodici celle raggruppate in Watts, Weights e Will, aggregando con una media a elasticità di sostituzione costante con  $\sigma = 0,33$ , così che una singola cella debole vincoli il totale anziché essere annullata dalla media; la sua stessa documentazione registra che il 37% delle misurazioni sottostanti è giudizio dell'analista e che non è modellata alcuna dimensione temporale, né decadimento, ammortamento, tasso di guasto o scenario di recisione. Il Sovereign AI Index del CNAS (2026) cataloga oltre 139 progetti sostenuti da Stati e rileva che la maggior parte resta dipendente da tecnologia estera, prevalentemente statunitense, lungo l'intero stack; non è, esplicitamente, un modello di dipendenza e recisione. Gli strumenti accademici hanno struttura analoga: Lee et al. (2024) scompongono la sovranità tecnologica in capacità di innovazione, capacità produttiva e indipendenza della catena di fornitura per

l'industria dei semiconduttori; Caravella et al. (2023) tracciano le dipendenze strategiche lungo la filiera fotovoltaica; Cai et al. (2026) passano in rassegna 104 articoli su politica industriale dei semiconduttori e governance degli ecosistemi regionali. Strumenti più ampi, il Government AI Readiness Index, il Global AI Index, l'AI Index annuale, estendono la copertura senza modificare la logica temporale.

Ognuno di questi è trasversale nel tempo. La letteratura metodologica sugli indicatori compositi è essa stessa esplicita nel riconoscere che ponderazione, aggregazione e robustezza sono il punto in cui simili strumenti riescono o falliscono (Greco et al., 2018; Dobbie et al., 2013; Kelemen et al., 2024; OCSE/JRC, 2008), e ne adottiamo la disciplina più avanti. Ma nessuna cura nell'aggregazione converte una fotografia in una traiettoria.

## 2.2 Governance del calcolo e affidabilità degli acceleratori

Sastry et al. (2024) stabiliscono il quadro di riferimento: la potenza di calcolo è un oggetto trattabile di policy perché è rilevabile, escludibile, quantificabile e prodotta attraverso una catena di fornitura estremamente concentrata. Queste quattro proprietà sono precisamente le condizioni che rendono possibile un modello di recisione; il presente articolo può essere letto come il successore quantitativo di quell'argomento qualitativo. La prassi regolatoria si è mossa nella stessa direzione, assumendo la potenza di elaborazione cumulata, e non il conteggio delle unità, come grandezza controllata.

Sul versante hardware, Grattafiori et al. (2024) riportano statistiche di interruzione risolte per componente per un addestramento su 16.384 acceleratori, e Kokolis et al. (2025) stimano modelli di guasto su oltre 150 milioni di ore-acceleratore distribuite su due cluster di produzione. L'analisi di Epoch AI conclude che il guasto hardware non limiterà la scalabilità, in regime di rifornimento continuo. È la nostra lettura di quella condizione al contorno, dichiarata nella fonte stessa, a motivare questo lavoro.

Una terza tradizione è più vicina di entrambe e va riconosciuta: la modellistica militare del sostegno logistico. Il METRIC di Sherbrooke (1968) e la tradizione multi-echelon che ha fondato ottimizzano le scorte di ricambi recuperabili per la disponibilità di flotta, e le sue estensioni moderne incorporano esplicitamente la cannibalizzazione. È il parente quantitativo più prossimo del nostro termine di recupero, e ne prendiamo in prestito il lessico. Differisce esattamente sui margini che servono a questo articolo: ottimizza l'inventario sotto una filiera di rifornimento funzionante anziché sotto recisione totale, e i suoi sistemi non affrontano alcuna frontiera di capacità in movimento, un velivolo che vola è disponibile, mentre un acceleratore che funziona può essere già strategicamente obsoleto. La soglia  $\kappa^*$  va dunque letta come il limite in regime di recisione di quella tradizione, non come la pretesa di aver scoperto la cannibalizzazione.

## 2.3 Statecraft economico e punti di strozzatura

Farrell e Newman (2019) forniscono il quadro teorico: una topologia di rete asimmetrica consente agli Stati che hanno giurisdizione sui nodi centrali di esercitare un *effetto panopticon* e un *effetto punto di strozzatura*, il secondo dei quali nega l'accesso alla rete agli avversari. Beaumier et al. (2023) applicano l'analisi di rete direttamente ai semiconduttori, scomponendo la filiera in reti di progettazione, materie prime, apparecchiature di produzione e chip assemblati, e mostrando come la centralità in una consenta di rendere arma un'altra. Fuller (2026) sostiene che il quadro si trasferisca imperfettamente ai beni fisici, dove un punto di strozzatura si intende meglio come un input senza il quale un compito non può proseguire, formulazione che si sovrappone strettamente al modello qui sviluppato.

La valutazione quantitativa dei controlli si è concentrata sugli aggregati economici. Park e Liu (2023) impiegano metodi input-output multiregionali; Cui et al. (2025) adottano un modello di equilibrio economico generale dinamico per stimare gli effetti sul PIL dell'embargo sui chip e dei contro-controlli cinesi su gallio, germanio e grafite; Shrivastava et al. (2025) valutano l'elusione. La resilienza delle filiere è stata modellata con topologie a cascata scale-free e reti bayesiane. Tutto ciò misura la **conseguenza economica**. Nessuno misura il **decadimento della capacità nel tempo**.

L'analisi di settore è quella che vi si avvicina di più. Sono state pubblicate stime del momento in cui una scorta di die non assemblati si esaurirà, compresa una formulazione zero-inflated che assegna circa il 56% di probabilità all'esaurimento di una di tali scorte entro il gennaio 2026. Quel lavoro modella lo *smaltimento di magazzino*, componenti in attesa di assemblaggio. Il presente articolo modella il *decadimento del parco*

installato, hardware già dispiegato e in funzione. Sono due domande diverse con matematiche diverse, e ci limitiamo scrupolosamente a rivendicare la seconda.

*La letteratura esistente misura ciò che una giurisdizione possiede, ciò che può costruire e quanto la recisione costi alla sua economia. Questo articolo misura per quanto tempo ciò che possiede continui a funzionare.*

### 3 Il modello

#### 3.1 Impostazione

Sia  $N(t)$  il numero di acceleratori operativi, in equivalenti-H100 (H100e), al mese  $t$  successivo alla recisione, con  $N(0) = C_0$ . Il calcolo nazionale effettivo è

$$C(t) = N(t) u(t) \quad (1)$$

dove  $u(t) \in (0,1]$  è un tetto di utilizzo imposto da vincoli energetici, di interconnessione e operativi. Tre flussi agiscono su  $N$  in ciascun periodo. I guasti hardware avvengono con rischio mensile  $\lambda = -\ln(1-AFR)/12$ . L'obsolescenza ritira unità al tasso  $\delta = 1/L$ , con  $L$  la vita utile in mesi; le unità ritirate restano fisicamente integre. La sostituzione arriva come produzione interna più dispersione,  $R = R_{int} + R_{disp}$ .

Il meccanismo che distingue la recisione dal funzionamento ordinario è il recupero di componenti. In regime di rifornimento un'unità guasta viene sostituita e  $N$  resta invariato, ed è per questo che le analisi di affidabilità concludono che i guasti non vincolano. In regime di recisione l'unica fonte di riparazione sono le altre unità. Sia  $P(t)$  il bacino di riparazioni recuperabili e sia  $\kappa$  la *resa di cannibalizzazione*: il numero di riparazioni ricavabili da una unità donatrice. Allora

$$F_t = N_t \lambda, \quad \text{Rit}_t = N_t \delta$$

$$\rho_t = \min(F_t, P_t)$$

$$P_{t+1} = P_t - \rho_t + \kappa (F_t - \rho_t + \text{Rit}_t)$$

$$N_{t+1} = N_t - F_t - \text{Rit}_t - S_t + \rho_t + R \quad (2)$$

dove  $S_t$  è il numero di unità *ancora efficienti* ritirate volontariamente per ricavarne componenti. Il ritiro è razionale solo quando una donatrice rende più di una riparazione, cosicché  $S_t > 0$  richiede  $\kappa > 1$ ; lo limitiamo al 3% della flotta al mese.

#### 3.2 La resa critica di cannibalizzazione

Il bacino di recupero è alimentato dalle unità che escono dal servizio e prosciugato dalle riparazioni. I soli ritiri sostengono il flusso di riparazione quando  $\kappa N \delta \geq N \lambda$ , il che fornisce una soglia indipendente dalla dimensione della flotta, dagli afflussi e dalle politiche:

$$\kappa^* = \frac{\lambda}{\delta} = \lambda L \quad (3)$$

$\kappa^*$  è una soglia di **saturazione**, non di sopravvivenza, e la distinzione conta. Al di sopra, il recupero assorbe di fatto l'intero flusso di guasti e il parco installato declina al solo tasso di obsolescenza; ulteriore capacità di recupero non produce alcun beneficio. Al di sotto, i guasti non riparati si sommano ai ritiri e, con  $\kappa = 0$ , il parco si contrae del 40% più rapidamente di quanto la sola obsolescenza implicherebbe. Ciò che  $\kappa^*$  separa è dunque un regime *limitato dai guasti* da uno *limitato dall'obsolescenza*. Non separa la sopravvivenza dal collasso: in assenza di afflussi di sostituzione ogni parco declina, perché il ritiro rimuove unità indipendentemente dalla riparazione dei guasti.  $\kappa^*$  è una proprietà dell'hardware, del suo tasso di guasto e della sua vita utile, non della giurisdizione che lo detiene. L'Appendice A ne riporta la derivazione; il §5.1 la verifica.

È qui che l'architettura fisica degli acceleratori diventa decisiva, ed è qui che l'analogia con altre flotte di capitale si rompe. Una cellula aeronautica è ricca di ricambi: si scompone in migliaia di unità sostituibili che si guastano indipendentemente, e la prassi osservata sotto sanzioni è stata smontare circa un velivolo per tenerne in volo una decina, il che implica  $\kappa \approx 10$ . Un acceleratore per IA è povero di ricambi esattamente nel punto sbagliato. La memoria ad alta banda è integrata nello stesso package del die logico su un interposer condiviso; né il die né lo stack di memoria sono unità sostituibili sul campo. I due modi di guasto dominanti sono dunque non recuperabili **per costruzione**, e la cannibalizzazione recupera soltanto componenti accessorie del nodo, alimentatori, interfacce di rete, raffreddamento, che non sono i modi di guasto vincolanti. Assumiamo  $\kappa \in [0,05; 0,50]$  per gli acceleratori e trattiamo il valore aeronautico come limite superiore appartenente a una diversa classe di hardware.

### 3.3 Grandezze riportate

- **Emivita del calcolo**  $T_{1/2}$ , mesi necessari perché il calcolo effettivo scenda sotto la metà del valore al giorno della recisione. Censurata a destra all'orizzonte di 120 mesi.
- **Tempo di uscita dalla frontiera**  $T_f$ , mesi necessari perché la capacità nazionale scenda sotto una quota soglia  $\theta = 0,10$  della scala di addestramento di frontiera contemporanea  $F(t) = F_0 2^{t/T_{ddp}}$ , dove  $F_0$  è un ancoraggio **assoluto e comune a tutte le giurisdizioni**. Una versione precedente normalizzava invece rispetto al  $C_0$  di ciascuna giurisdizione, il che imponeva a tutte di partire alla pari e faceva cancellare identicamente  $C_0$ ; l'apparente invarianza rispetto allo stock che ne derivava era un artefatto algebrico ed è stata ritirata (§5.3, Appendice A).
- **Soglia di sovranità**  $C_\infty$ , il livello asintotico come quota di  $C_0$ , sostenibile con tutti gli afflussi non recisi, produzione interna e dispersione residua, mantenuti al tasso del giorno della recisione. Una forma chiusa esiste ed è riportata nell'Appendice A; riproduce esattamente l'integrazione a 900 mesi.  $C_\infty$  è definita solo per crescita dell'indigenizzazione nulla (§7.4).

L'ancoraggio  $F_0$  merita una derivazione alla luce del sole, poiché  $T_f$  lo eredita attraverso il logaritmo. Un addestramento di frontiera da  $10^{26}$  a  $10^{27}$  FLOP, eseguito in circa tre mesi su acceleratori che sostengono  $4 \times 10^{14}$  FLOP/s effettivi, corrisponde a circa  $3 \times 10^{21}$  FLOP per acceleratore e dunque a  $3 \times 10^4$  fino a  $3 \times 10^5$  H100e per esecuzione. Le stime correnti delimitano lo stesso intervallo: la prima esecuzione dichiarata sopra  $10^{26}$  FLOP è stata Grok 3 nel febbraio 2025, a circa  $3 \times 10^{26}$ ; la più grande a oggi è Grok 4; ed Epoch AI colloca il superamento di  $10^{26}$  da parte del primo modello di frontiera attorno al gennaio 2026. Percorriamo quindi  $F_0$  in modo log-uniforme fra  $5 \times 10^4$  e  $5 \times 10^5$  H100e con valore centrale  $1,5 \times 10^5$ , e ogni  $T_f$  riportato incorpora tale incertezza.

## 4 Dati e parametri

### 4.1 Tassi di guasto derivati dalla telemetria dei cluster

Grattafiori et al. (2024) riportano 419 interruzioni inattese in una finestra di pre-addestramento di 54 giorni su un cluster di un massimo di 16.384 acceleratori H100, risolte per causa: acceleratore difettoso 148 (30,1%), memoria HBM3 dell'acceleratore 72 (17,2%), switch o cavo di rete 35 (8,4%). Annualizzando per acceleratore,

$$\text{AFR} = \frac{n_{\text{eventi}}}{16,384} \times \frac{365}{54} \quad (4)$$

si ottiene il 6,11% annuo per i guasti del die e il 2,97% per la HBM3, dunque un **tasso di guasto di package del 9,08% annuo** per i due modi non sostituibili sul campo, e il 17,29% considerando tutte le cause di interruzione. Come verifica indipendente, il dato onnicomprensivo corrisponde a un'interruzione ogni 50.677 ore-acceleratore, contro circa 50.000 riportate da Epoch AI sulla medesima esecuzione, un accordo entro l'1,4%. Assumiamo il tasso di package come valore centrale e percorriamo l'intero intervallo nel Monte Carlo. Una cautela accompagna questi tassi: i conteggi delle interruzioni non distinguono la morte definitiva dell'hardware dai guasti transitori risolti con un riavvio, sicché, nella misura in cui alcune interruzioni attribuite al die erano recuperabili, il tasso di package sovrastima l'attrito permanente. La direzione di questa distorsione è benigna per le nostre conclusioni: un  $\lambda$  più basso allunga  $T_{1/2}$ , alza le soglie e lascia  $T_f$  quasi invariato.

#### 4.2 Parco installato

Epoch AI stima uno stock globale consegnato di circa 15 milioni di H100e e pubblica dati risolti per proprietario. Per la Cina deriviamo  $C_0$  da una relazione pubblicata anziché da un'ipotesi: la stima mediana di 660.000 H100e dirottati entro il 2025 è descritta come pari a circa un terzo della capacità totale cinese, da cui  $C_0 \approx 1.980.000$  H100e. L'intervallo al 90% sulla stima di contrabbando (290.000-1.600.000) è propagato direttamente.

**Questo è il limite principale dei dati dello studio e lo dichiariamo apertamente.** Epoch risolve la proprietà per *impresa*, non per *giurisdizione*. Attribuire a un paese il parco di un operatore multinazionale richiede ipotesi non pienamente difendibili sulla base di dati pubblici. Percorriamo quindi la quota statunitense fra il 60% e il 78% e quella dell'Unione Europea fra il 2% e il 6% dello stock globale, e riportiamo i risultati europei con confidenza corrispondentemente bassa. Nessuna conclusione di questo articolo dipende da una stima puntuale dello stock nazionale.

#### 4.3 La recisione è modellata in modo simmetrico

Una giurisdizione è recisa dagli input che non controlla. Vale la pena sottolineare che non si tratta di uno scenario specificamente cinese. Gli Stati Uniti non dispongono di una fonte interna di litografia a ultravioletto estremo, detengono capacità di produzione all'avanguardia solo parziale e ancora in fase di avviamento, e non producono memoria ad alta banda su scala, la fornitura di HBM è concentrata per circa il 90% in due imprese coreane. La copertura interna statunitense in regime di recisione dai propri alleati è dunque una banda di scenario (15-35%), non l'unità. All'Unione Europea, priva di produzione di logica all'avanguardia in esercizio, è assegnato l'1-4%.

**Tabella 1.** Parametri del modello, intervalli e fonti.

| Simbolo    | Parametro                            | Centrale    | Intervallo             | Fonte                                                   |
|------------|--------------------------------------|-------------|------------------------|---------------------------------------------------------|
| $\lambda$  | Tasso di guasto package (annuo)      | 9,08%       | 6,11-17,29%            | Derivato, Grattafiori et al. (2024)                     |
| $\kappa$   | Resa di cannibalizzazione            | 0,275       | 0,05-0,50              | Architettura del package (§3.2)                         |
| $L$        | Vita utile (anni)                    | 4,0         | 2,0-6,0                | Controversia sull'ammortamento, 2025-26                 |
| $T_{ddp}$  | Raddoppio frontiera (mesi)           | 5,2         | 4,8-7,0                | Epoch AI, serie dell' <i>addestramento</i> di frontiera |
| $F_0$      | Ancoraggio di frontiera (H100e)      | 150.000     | 50k-500k               | Derivato; v. §3.3. Percorso log-uniforme                |
| $\theta$   | Soglia di competitività              | 0,10        | fissa                  | Convenzione; entra via logaritmo (§5.3)                 |
| $cov$      | Copertura interna USA / UE           | 0,25 / 0,02 | 0,15-0,35 / 0,01-0,04  | <b>Assunzione, senza base osservativa</b>               |
| $C_0^{CN}$ | Stock Cina (H100e)                   | 1.980.000   | 0,87-4,80 mln          | Derivato, Epoch AI                                      |
| $C_0^{US}$ | Stock USA (H100e)                    | 10.500.000  | 9,0-11,7 mln           | Epoch AI, quota variata                                 |
| $C_0^{EU}$ | Stock UE (H100e)                     | 600.000     | 0,3-0,9 mln            | Scenario, confidenza bassa                              |
| $R_{int}$  | Produzione interna Cina (H100e/mese) | 28.708      | 30-100% del tasso 2025 | Output realizzato (Epoch AI) × dipendenza dalle scorte  |
| $R_{disp}$ | Dispersione (H100e/mese)             | 9.625       | 10-60% della base      | Derivato, Epoch AI (2026)                               |


H100e = equivalenti-H100. Gli intervalli sono propagati con un Monte Carlo a 10.000 estrazioni con campionamento uniforme indipendente. L'indipendenza è essa stessa un'assunzione: correlazioni plausibili fra i parametri, fra vita utile e tasso di guasto, o fra stock e capacità interna, non sono modellate.

5 Risultati

5.1 L'intervallo plausibile è a cavallo della soglia

Con i parametri centrali  $\kappa^* = 0,38$ . Sull'intera griglia dei parametri varia da 0,13 (soli guasti del die, vita utile biennale) a 1,14 (tutte le cause, vita utile sessennale). L'intervallo plausibile per gli acceleratori,  $[0,05; 0,50]$ , è **a cavallo della soglia centrale**. La misura diretta sul modello integrato conferma l'algebra: contro un declino da soli ritiri pari al 2,08% mensile, il parco si contrae del 2,92% al mese con  $\kappa = 0$  (eccesso del 40%), scendendo al 2,14% in corrispondenza di  $\kappa^*$  (eccesso del 3%), dopo di che triplicare  $\kappa$  lo modifica di meno del 2%. Un parco al di sotto della soglia paga quindi una penalità cumulativa, mentre uno al di sopra non trae alcun vantaggio da ulteriore capacità di recupero. Stabilire empiricamente  $\kappa$  è, su questa analisi, la misurazione di maggior valore che il campo potrebbe intraprendere.

La soglia interagisce con la controversia sull'ammortamento in un modo che vale la pena esplicitare. Poiché  $\kappa^* = \lambda L$  cresce con la vita utile, un parco più longevo si colloca più in basso rispetto a qualunque capacità di recupero fissata: sull'intervallo conteso di due-sei anni la quota di guasti che il recupero può assorbire scende dal 100% al 48%. Abbiamo verificato, e respinto, l'inferenza allettante che i parchi più longevi siano perciò complessivamente più fragili: il tempo di dimezzamento senza afflussi *cresce* da 17 a 41 mesi sullo stesso intervallo, perché il ritiro più lento prevale. L'affermazione difendibile è più stretta: un parco a sei anni sopravvive più a lungo in termini assoluti, ma dipende di più dallo stock grezzo e di meno dalla riparazione. Riportiamo l'ipotesi respinta perché è allettante, citabile e falsa.



**Figura 1.** La resa critica di cannibalizzazione  $\kappa^* = \lambda L$  in funzione della vita utile, per tre ipotesi sul tasso di guasto. La banda ombreggiata è l'intervallo plausibile per gli acceleratori di IA, dato che la memoria ad alta banda è integrata nello stesso package e non è sostituibile sul campo. La banda interseca tutte e tre le curve: che il recupero sostenga un parco installato dipende dal regime, non è una questione di grado.

## 5.2 Traiettorie e grandezze riportate


La Tabella 2 riporta mediane e intervalli al 90% su 10.000 estrazioni per giurisdizione. L'uscita dalla frontiera avviene fra 25 e 49 mesi, ordinata secondo il parco installato come la relazione analitica del §5.3 richiede. Alla mediana nessuna giurisdizione raggiunge l'autosufficienza, ma le soglie vanno lette con doppia cautela: per Stati Uniti e Unione Europea sono il parametro di copertura interna assunto, riscalato di un fattore limitato, non un esito indipendente del modello (§7.2), mentre l'intervallo al 90% della Cina raggiunge il 155,7%, sopra la parità. Le soglie di sovranità mediane sono il 31,1% per gli Stati Uniti, il 53,4% per la Cina e il 3,1% per l'Unione Europea.

**Tabella 2.** Grandezze riportate per giurisdizione. Mediane con intervalli al 90%, 10.000 estrazioni Monte Carlo.


| Giurisdizione  | $C_0$ (mln H100e) | $T_{1/2}$ (mesi) | $T_f$ (mesi) | $C_\infty$ (% di $C_0$ ) | $P(T_{1/2} \leq 36)$ |
|----------------|-------------------|------------------|--------------|--------------------------|----------------------|
| Cina           | 1,98              | >120 [29->120]   | 41 [30-54]   | 53,4 [22,1-155,7]        | 11,3%                |
| Stati Uniti    | 10,50             | 51 [28-111]      | 49 [38-63]   | 31,1 [19,5-44,7]         | 19,2%                |
| Unione Europea | 0,60              | 28 [18-43]       | 25 [17-36]   | 3,1 [1,4-5,0]            | 82,5%                |

$T_{1/2}$  è censurata a destra a 120 mesi. Le estrazioni censurate sono conservate ordinalmente, sicché ogni quantile che cada nella massa censurata è riportato come '>120' anziché come valore finito; la censura riguarda il 57,7% delle estrazioni cinesi e il 3,8% di quelle statunitensi. I valori europei hanno confidenza bassa perché i dati di stock risolti per giurisdizione sono i più deboli (§4.2).





**Figura 2.** Decadimento del calcolo effettivo dopo la recisione, caso centrale. La traiettoria europea è la più rapida nonostante la minore esposizione assoluta, perché la sostituzione interna copre la quota più bassa del proprio attrito.



**Figura 3.** Distribuzione Monte Carlo per la Cina, 10.000 estrazioni con campionamento uniforme indipendente su tutti i parametri della Tabella 1. L'ampiezza dell'intervallo al 90% riflette il campionamento congiunto di tutti i parametri; poiché gli afflussi cinesi sono assoluti e non proporzionali allo stock, contribuisce anche l'incertezza su  $C_0$ .

### 5.3 L'orologio della frontiera domina l'attrito hardware


Il risultato rilevante non è il decadimento dell'hardware, ma la sua modesta quota dell'intervallo. La Figura 4 rappresenta la capacità rispetto alla scala di frontiera contemporanea. Trascurando del tutto il decadimento, il tempo di uscita segue

$$T_f \simeq T_{ddp} \log_2 \left( \frac{C_0}{\theta F_0} \right) \quad (5)$$

che riproduce i casi centrali simulati entro quattro mesi (analitico 36,6 / 49,1 / 27,7 contro simulato 36 / 45 / 24 per Cina, Stati Uniti e Unione Europea). Ne discendono due conseguenze, che sostituiscono l'affermazione di invarianza rispetto allo stock avanzata in una versione precedente.


- **Il parco installato compra tempo solo in modo logaritmico.** Con  $T_{ddp} = 5,2$  mesi, un parco dieci volte più grande compra  $T_{ddp} \log_2 10 \approx 17$  mesi ulteriori, e uno cento volte più grande soltanto 35. L'accumulo di scorte è soggetto a rendimenti fortemente decrescenti contro una frontiera in movimento, un'affermazione più forte e più utile di quella di invarianza che sostituisce, e a differenza di quella non è un artefatto di normalizzazione.
- **Il decadimento hardware pesa per una minoranza costante dell'intervallo.** Rieseguendo ciascun caso centrale con guasto e ritiro azzerati si ottengono 42 / 52 / 28 mesi contro 36 / 45 / 24 con il decadimento: l'attrito costa 6 / 7 / 4 mesi, cioè il **13-14% del bilancio** in tutte e tre le giurisdizioni. Il restante 86% è l'orologio della frontiera.

La lettura corretta è dunque più stretta dell'originale ma regge alla verifica: l'affidabilità dell'hardware non governa la posizione strategica in regime di recisione, ma neppure la posizione è indipendente da quanto hardware una giurisdizione detenga.



**Figura 4.** Capacità relativa alla frontiera mobile, scala logaritmica. Tutte e tre le giurisdizioni partono da posizioni diverse perché i parchi installati differiscono; il declino quasi parallelo riflette il deflatore comune di frontiera. I tempi di attraversamento sono ordinati secondo lo stock e separati da circa  $T_{ddp} \log_2$  del rapporto fra gli stock.

L'analisi di sensibilità conferma il meccanismo. Facendo variare il tempo di raddoppio della frontiera nel suo intervallo di 4,8-7,0 mesi,  $T_f$  si sposta di 15 mesi; facendo variare il tasso di guasto sull'intero intervallo derivato, si sposta di 2 mesi, una differenza di leva di sette volte. L'affidabilità dell'hardware, la grandezza che la letteratura ingegneristica misura con maggiore cura, è fra i parametri *meno* importanti per l'esito strategico.




**Figura 5.** Sensibilità univariata del tempo di uscita dalla frontiera, ordinata per ampiezza. Il ritmo di avanzamento della frontiera domina; resa di cannibalizzazione e tasso di guasto contano meno una volta fissato il regime.

La soglia  $\theta = 0,10$  è una convenzione, e la sua influenza è del tutto trasparente: entra nell'Eq. 5 solo attraverso il logaritmo, sicché dimezzarla allunga ogni  $T_f$  di esattamente un tempo di raddoppio, circa cinque mesi, e raddoppiarla lo accorcia della stessa quantità, lasciando intatti ordinamento e distanze. Verificato numericamente: 42 / 36 / 31 mesi per  $\theta = 0,05 / 0,10 / 0,20$  nel caso centrale cinese.

5.4 Dipendenza dal regime

La Figura 6 mostra le traiettorie nei diversi regimi di cannibalizzazione. I valori di  $\kappa$  superiori a  $\kappa^* = 0,38$ , compreso il valore aeronautico di 10, un ipotetico acceleratore riparabile sul campo a 1, e il limite superiore dell'intervallo plausibile a 0,5, sono indistinguibili, perché tutti e tre sono oltre la saturazione e il flusso di guasti è già interamente assorbito. Solo il limite inferiore, 0,05, si colloca abbastanza sotto la soglia da incidere sul declino. Il sistema non risponde con continuità a  $\kappa$ : satura.



**Figura 6.** Decadimento in quattro regimi di cannibalizzazione. Le tre curve pari o superiori alla resa critica coincidono perché tutte sono oltre la saturazione: il flusso di guasti è già assorbito e la capacità aggiuntiva resta inutilizzata.

5.5 Recisione parziale: che cosa compra davvero la dispersione


I controlli reali non sono né completi né istantanei. Sono permeabili, per dirottamento, rivendita e triangolazione via paesi terzi, e l'entità di questa dispersione è precisamente la grandezza che le politiche di enforcement contendono. Percorrendo il termine di dispersione su quattro ordini di grandezza si separano due effetti che di solito vengono discussi come uno solo.

I due orizzonti rispondono alla dispersione con elasticità molto diverse. Su un intervallo da zero al 200% del parco installato all'anno, la soglia di sovranità sale dal 64% al 803% di  $C_0$ , un fattore 12, mentre l'uscita dalla frontiera passa solo da 35 a 50 mesi, una variazione del 43%. L'asimmetria discende direttamente dalla forma analitica: la soglia è uno stato stazionario determinato dagli afflussi e scala linearmente in essi, mentre  $T_f$  vi entra attraverso un logaritmo e un denominatore che cresce esponenzialmente. Raggiungere una soglia del 100% di  $C_0$  costa circa il 10% del parco installato all'anno e compra 2 mesi aggiuntivi alla frontiera.

**Tabella 3.** Recisione parziale. Effetto della dispersione sui due orizzonti.

| Regime di dispersione         | H100e / mese | % di $C_0$ all'anno | $T_f$ (mesi) | $C_\infty$ (% di $C_0$ ) |
|-------------------------------|--------------|---------------------|--------------|--------------------------|
| Nessuna                       | 0            | 0                   | 35           | 64                       |
| Soglia tenuta al 100%         | 17.253       | 10,5                | 37           | 100                      |
| Equivalente di mercato aperto | ,            | 200                 | 50           | 803                      |

I tassi di dispersione sono espressi rispetto al flusso di dirottamento storicamente stimato. La soglia è molto elastica alla dispersione; l'orizzonte di frontiera non lo è.




**Figura 7.** La dispersione alza rapidamente la soglia di sovranità muovendo pochissimo l'orizzonte di frontiera. Le due curve divergono perché la soglia è uno stato stazionario determinato dagli afflussi, mentre l'uscita dalla frontiera è governata dal tasso di crescita della frontiera stessa.

**La dispersione compra capacità, non competitività.** Per il disegno dell'enforcement questo rovescia l'enfasi consueta. L'interdizione è relativamente efficace nel proteggere un vantaggio di frontiera, robusto alla dispersione perché determinato dal tasso di crescita della frontiera e non dallo stock dell'avversario. È quasi impotente nell'impedire a un avversario di mantenere una soglia sostanziale, perché la soglia risponde direttamente agli afflussi e l'afflusso richiesto è modesto. Un regime di controllo giustificato sul primo terreno e valutato sul secondo apparirà fallimentare quando non lo è, e viceversa.

## 6 Il confronto aeronautico, e perché la calibrazione fallisce

Un modello di recisione si espone all'obiezione di essere infalsificabile, poiché nessuna giurisdizione è stata finora recisa integralmente dal calcolo per IA. La risposta naturale è calibrare sul caso osservato più prossimo. L'aviazione civile russa dopo il febbraio 2022 è l'unica recisione documentata di una flotta di capitale complessa e dipendente dai ricambi con una finestra di osservazione pluriennale: una flotta iniziale di circa 1.500-1.800 velivoli di costruzione occidentale, oltre un terzo dei quali risultava cannibalizzato entro l'ottobre 2025, una riduzione prevista superiore al 50% entro il 2026, e una prassi documentata di smontare circa un velivolo per tenerne in volo dieci.

**Abbiamo tentato questa calibrazione e fallisce.** Stimando il rischio del modello come unico parametro libero con  $\kappa = 10$  fissato dalla prassi osservata, il migliore adattamento ottenibile raggiunge un errore quadratico medio di 0,222 e lascia inspiegati 34 punti percentuali del declino osservato al mese 47, con il rischio stimato appiattito contro il limite superiore della griglia di ricerca.



**Figura 8.** Flotta civile russa osservata contro il migliore adattamento ottenibile con il solo attrito dei ricambi. Il residuo ombreggiato è la quota di declino che l'attrito dei ricambi non può spiegare. Non è errore del modello: corrisponde a meccanismi privi di analogo nel calcolo.

Il residuo è informativo, non imbarazzante. Due meccanismi determinano gran parte del declino osservato e non hanno corrispettivo nel calcolo: il sequestro da parte dei locatori dei velivoli di proprietà estera, che è uno shock una tantum sullo stock e non attrito, e il ritiro dell'idoneità al volo da parte dei regolatori, che rimuove velivoli efficienti per ragioni giuridiche anziché fisiche. Gli acceleratori sono di proprietà piena e nessun regolatore mette a terra un cluster degradato. Attribuire all'attrito dei ricambi l'intero declino russo sovrastimerebbe il rischio di circa un ordine di grandezza.

Usiamo dunque l'aviazione per delimitare  $\kappa$  e per stabilire che la cannibalizzazione è un meccanismo reale, osservato e quantificato, non per calibrare il modello del calcolo. Riportare questo risultato negativo è importante per due ragioni. Impedisce che una calibrazione spuriamente precisa si propaghi nella letteratura, e individua esattamente ciò che un test empirico adeguato richiederebbe: telemetria di un parco sottoposto a un vincolo reale di riapprovvigionamento, che allo stato non esiste in forma pubblica.

Un risultato qualitativo si trasferisce comunque. La frequenza degli incidenti riportata per la flotta russa è più che raddoppiata rispetto al 2019 ben prima che il numero dei velivoli si dimezzasse. Il degrado si manifesta come calo di affidabilità prima di manifestarsi come calo di inventario. Se lo stesso vale per il calcolo, la capacità effettiva scende più rapidamente di quanto il conteggio dei nodi suggerisca, e le nostre stime sono conservative.

## 7 Discussione

### 7.1 Che cosa fa guadagnare davvero la recisione

I risultati sostengono una riformulazione del dibattito sui controlli alle esportazioni. La grandezza rilevante non è quanto calcolo perda un avversario, ma quanto tempo impieghi a cadere fuori da una frontiera in movimento, e secondo le nostre stime tale intervallo è di circa due anni ed è notevolmente insensibile alla dimensione del parco installato. I controlli non devono distruggere capacità: devono soltanto mantenerla costante mentre la frontiera avanza. Per converso, una giurisdizione che si sia assicurata un ampio parco di acceleratori ha comprato meno tempo strategico di quanto la sua dimensione suggerisca, perché il vincolo operante è il tasso di crescita della frontiera e non il proprio hardware.

Ne discende un'implicazione simmetrica e meno confortante. Se l'avanzamento della frontiera rallenta, per limiti di scala, vincoli energetici o ritiro di capitali, il valore dei controlli decade con esso. In questa lettura i controlli alle esportazioni sono una scommessa sulla prosecuzione del progresso esponenziale. Sono massimamente efficaci proprio quando meno servirebbero a stabilire un primato, e minimamente efficaci quando il progresso si arresta e gli stock installati conservano il proprio valore relativo.

### 7.2 La sovranità ha un numero, ed è ovunque basso

La soglia di sovranità esplicita qualcosa che la letteratura degli indici ha indicato senza quantificare, ma va letta con un'avvertenza che enunciamo prima del risultato, non dopo. L'Appendice A mostra che, dove la produzione interna è parametrizzata come frazione di copertura dello stock installato, come per Stati Uniti e Unione Europea, la soglia collassa in  $cov(I + \min(\kappa, \kappa^*))$ , indipendente da  $C_0$ ,  $\lambda$  e  $L$ . Il dato statunitense del 31,1% è dunque la banda di copertura assunta (15-35%) riscalata di un fattore compreso fra 1,0 e 1,5, non un risultato indipendente. Lo riportiamo come **mappatura di scenario**: una copertura di 0,15 / 0,25 / 0,35 implica una soglia del 19 / 32 / 45%, e chi contesta l'assunzione di copertura può sostituirla propria. La soglia cinese (53,4%) è di natura diversa, deriva da una stima di afflusso assoluto, non da una frazione di copertura, ed è l'unica delle tre a essere un esito del modello in senso proprio. Il suo intervallo va allora preso sul serio: la banda al 90% corre dal 22,1% al 155,7% del parco installato, attraversando la parità in alto. L'estremo superiore è mosso congiuntamente dal parametro di dipendenza dalle scorte, se l'output realizzato di Huawei nel 2025 sia sostenibile senza le scorte di die TSMC pre-controlli, e dall'ampia incertezza sullo stesso  $C_0$ . Il modello non autorizza quindi l'affermazione che la Cina non possa sostenere internamente il proprio parco: autorizza l'agnosticismo, e indica la misura che risolverebbe la questione, la quota di dipendenza dalle scorte, come il secondo bersaglio empirico di maggior valore dopo  $\kappa$ .

Con questa qualificazione il punto qualitativo regge, e non dipende dal parametro conteso. La litografia è olandese, la produzione all'avanguardia è taiwanese e la memoria ad alta banda è per circa il 90% coreana. Nessun partecipante a questo sistema può esserne reciso senza costi, e l'impostazione retorica per cui la sovranità sarebbe una proprietà che una parte possiede e l'altra no non è sostenuta da alcuna assunzione di copertura che consideriamo plausibile.

### 7.3 Previsioni verificabili

Il modello è falsificabile, e vale la pena essere precisi su come, perché un modello di recisione non verificabile è un saggio. Quattro previsioni ne discendono direttamente, ciascuna con l'osservazione che la smentirebbe.

- **L'affidabilità degrada prima dell'inventario.** In qualunque parco di calcolo operante sotto un vincolo reale di riapprovvigionamento, il tasso di job falliti non recuperati dovrebbe crescere in modo misurabile prima che il numero di nodi operativi cali sensibilmente. Smentita osservando conteggi di nodi che calano in proporzione ai tassi di guasto, o prima di essi.
- **Lo sforzo di recupero mostra un punto di saturazione, non un gradiente.** Gli operatori che aumentano la capacità di cannibalizzazione oltre la soglia non dovrebbero registrare ulteriori miglioramenti di disponibilità. Smentita da una relazione regolare e non saturante fra sforzo di recupero e disponibilità.
- **L'uscita dalla frontiera scala logaritmicamente con lo stock.** Fra giurisdizioni,  $T_f$  dovrebbe crescere di circa  $T_{ddp} \log_2(10) \approx 17$  mesi per ogni aumento di dieci volte del calcolo installato, non proporzionalmente. Smentita da una relazione lineare o quasi. (Una versione precedente proponeva la previsione opposta, il disaccoppiamento dallo stock, che con la metrica allora implementata era infalsificabile per costruzione.)
- **Il dirottamento muove la soglia, non la frontiera.** Periodi di dirottamento accresciuto dovrebbero elevare sensibilmente la capacità di calcolo sostenuta di una giurisdizione, lasciando i suoi maggiori addestramenti all'incirca dove l'orologio della frontiera li colloca. Smentita da addestramenti di scala di frontiera che seguono i volumi di dirottamento.

La prima è la più immediatamente verificabile: richiede soltanto che un operatore sotto vincolo pubblici la telemetria dei job falliti accanto ai conteggi dei nodi. Nessuna serie di questo tipo è oggi pubblica, ed è per questo che il §6 riporta una calibrazione fallita anziché una riuscita.

### 7.4 Limiti

- **Attribuzione giurisdizionale.** I migliori dati pubblici sugli stock risolvono la proprietà per impresa, non per paese. Percorriamo le quote anziché affermarle, ma nessun trattamento elimina del tutto questa debolezza. I risultati europei in particolare vanno letti come illustrazione di scenario.
- **$\kappa$  non è misurata.** La resa di cannibalizzazione è delimitata da ragionamento architeturale, non da osservazione, e l'intervallo plausibile è a cavallo della soglia critica. È il parametro aperto più rilevante.

- **L'utilizzo è tenuto costante.** I vincoli energetici e di rete sono rappresentati da un tetto fisso. Diverse analisi recenti sostengono che in alcune giurisdizioni sia ormai l'energia, e non il silicio, a vincolare; endogenizzare  $u(t)$  accorcerebbe verosimilmente gli orizzonti qui riportati.
- **La recisione è modellata come completa e istantanea.** I controlli reali sono parziali, gradualmente e permeabili. Il termine di dispersione ne cattura una parte; i regimi a fasce o a escalation non sono modellati.
- **La frontiera è esogena.** Trattiamo la crescita della frontiera come un'esponentiale esterna. In realtà l'uscita di una giurisdizione recisa dalla frontiera altera le dinamiche competitive e dunque la traiettoria della frontiera stessa.
- **Non esiste un caso empirico di recisione per il calcolo.** Il modello è falsificabile in linea di principio, prevede traiettorie di degrado specifiche, ma non può ancora essere verificato sull'osservazione, come stabilisce il §6.
- **Il ritiro è una scelta economica che il modello tratta come fisica.** La vita utile  $L$  codifica il ritiro a fine vita contabile, ma un operatore in regime di recisione plausibilmente farebbe funzionare l'hardware fino al guasto. Rieseguendo i casi centrali con  $L$  pari a quarant'anni,  $T_f$  cresce solo di tre o quattro mesi, ogni  $T_{1/2}$  si allunga e le soglie salgono in modo sostanziale: lo scenario di copertura statunitense dal 32% al 92% di  $C_0$ , la Cina dall'86% al 246%. Il funzionamento fino al guasto rafforza quindi i risultati sulla sovranità e sposta appena l'orologio della frontiera, ed è per questo che nei risultati principali riportiamo il caso conservativo con ritiro.
- **$T_f$  misura la posizione di calcolo, non la posizione di capacità.** L'efficienza algoritmica nei modelli linguistici ha storicamente dimezzato il calcolo necessario a prestazioni fisse circa ogni otto mesi (Ho et al., 2024). Nella misura in cui tali progressi sono pubblici, entrambe le parti ne beneficiano e l'ordinamento relativo si conserva, ma un parco congelato continua a guadagnare capacità assoluta, sicché attraversare  $\theta$  è più morbido in termini di capacità che in termini di FLOP. Nella misura in cui i progressi di frontiera restano proprietari, la parte recisa degrada più in fretta di quanto  $T_f$  suggerisca. La misura è esatta sull'hardware e deliberatamente agnostica sul software.
- **L'accesso remoto è fuori dal modello per costruzione.**  $N(t)$  conta gli acceleratori fisicamente installati e operati nella giurisdizione. Il calcolo noleggiato presso fornitori esteri non è in  $N(t)$  e, a differenza del termine di dispersione, le cui unità entrano nel parco e poi decadono a  $\lambda$  e  $\delta$ , la capacità in leasing è reintegrata dal locatore e non decade affatto. Ogni orizzonte qui riportato è dunque condizionato alla recisione hardware e all'interdizione effettiva dell'accesso remoto; contro la sola recisione hardware è un limite superiore dell'effetto. Una consolazione segue analiticamente: poiché il deflatore di frontiera è esponenziale, un leasing fisso di qualunque entità sposta  $T_f$  solo di  $T_{ddp} \log_2(1 + A/C_0)$ ; la capacità noleggiata sconfigge il meccanismo solo se cresce essa stessa al ritmo della frontiera,  $g^* = \ln 2 / T_{ddp} \approx 13\%$  al mese.
- **La produzione interna è congelata al tasso del giorno della recisione.** Il modello non contiene un canale di sostituzione indotta, sicché  $C_\infty$  è definita solo per crescita nulla dell'indigenizzazione; per qualunque tasso positivo non esiste alcun asintoto. L'assunzione è contraddetta dalla tendenza più recente della serie stessa da cui il parametro è calibrato, gli obiettivi cinesi di produzione di acceleratori risultano circa raddoppiati fra 2025 e 2026, benché, sotto la premessa di recisione completa del paper, con memoria coreana e litografia olandese entrambe ritirate, il tasso potrebbe plausibilmente avere entrambi i segni.  $T_f$  è robusto a questo: si sposta di pochi mesi per tassi di crescita da -30% a +60% annui, perché nessun ritmo plausibile di indigenizzazione compete con una frontiera che raddoppia ogni 5,2 mesi.

## 8 Conclusioni

La capacità nazionale di IA è stata misurata come stock almeno undici volte e modellata come flusso nemmeno una. Abbiamo sostenuto che il flusso è la grandezza rilevante per le politiche, costruito un modello di decadimento dei parchi installati di acceleratori in regime di recisione, parametrizzato su telemetria pubblicata anziché su ipotesi, e riportato tre grandezze pensate per essere riutilizzate: l'emivita del calcolo, il tempo di uscita dalla frontiera e la soglia di sovranità.

Quattro risultati si distinguono. Il recupero di componenti assorbe il flusso di guasti solo fino a una resa di saturazione  $\kappa^* = \lambda L \approx 0,38$  e, poiché la memoria ad alta banda è integrata nello stesso package del die, l'intervallo plausibile per gli acceleratori è a cavallo di quella soglia, il che rende  $\kappa$  il parametro non misurato di maggior valore per il campo. L'uscita dalla frontiera avviene fra due e quattro anni e cresce solo logicamente con il parco installato: un parco dieci volte più grande compra circa diciassette mesi in più, mentre il decadimento hardware pesa solo per il 13-14% dell'intervallo e l'orologio della frontiera per il resto. Alla mediana nessuna grande giurisdizione appare autosufficiente, benché per Stati Uniti e Unione Europea quel valore sia un'assunzione di copertura riscalata anziché un risultato indipendente, e l'intervallo cinese sia abbastanza ampio da attraversare la parità, lasciando lì la questione della sovranità genuinamente aperta. E la dispersione, quando è parziale, compra capacità anziché competitività: alza rapidamente la soglia di sovranità lasciando l'orizzonte di frontiera quasi dov'era.

L'affermazione secondo cui i controlli alle esportazioni fanno guadagnare tempo è, in questa analisi, corretta nella forma e sostanzialmente errata nel meccanismo che di solito le si attribuisce. Ciò che si guadagna non è il degrado dell'hardware avversario, ma il congelamento della sua posizione rispetto a una frontiera che continua a muoversi. Si tratta di uno strumento diverso, con una diversa data di scadenza, e come tale andrebbe argomentato.

## Appendice A Derivazione della resa critica

Sia  $P_t$  il bacino di recupero. In un periodo il bacino guadagna  $\kappa$  riparazioni per ogni unità che esce dal servizio, guasti non riparati ( $F_t - \rho_t$ ) e ritiri  $Rit_t$ , e perde  $\rho_t$  per le riparazioni effettuate. Si consideri lo stato stazionario in cui ogni guasto viene riparato, cosicché  $\rho_t = F_t = N\lambda$  e  $Rit_t = N\delta$ . Il bilancio del bacino è

$$\Delta P = \kappa N \delta - N \lambda \quad (A.1)$$

non negativo precisamente quando  $\kappa \geq \lambda/\delta$ . Ponendo  $\delta = 1/L$  si ottiene  $\kappa^* = \lambda L$ . La dimensione della flotta  $N$  si semplifica, dunque la soglia è indipendente dalla scala; l'afflusso  $R$  non compare, dunque è anche indipendente dalle politiche. Al di sotto di  $\kappa^*$  il bacino si esaurisce in tempo finito e i guasti non riparati si accumulano; al di sopra il bacino cresce senza limite e il vincolo di riparazione cessa di operare, ed è per questo che le traiettorie per  $\kappa = 0,5, 1$  e  $10$  coincidono nella Figura 6.

Si noti con attenzione ciò che questo *non* stabilisce. L'equazione A.1 governa il solo vincolo di riparazione. Il ritiro rimuove unità dal servizio indipendentemente dalla riparazione dei guasti, dunque  $N$  declina anche al di sopra della soglia, al tasso  $\delta$ , anziché a  $\delta$  più un termine di guasti non assorbiti. Una versione precedente di questo articolo affermava che il parco installato *persiste* al di sopra di  $\kappa^*$ ; la simulazione diretta la smentisce, e la lettura corretta, una soglia di saturazione che separa il decadimento limitato dai guasti da quello limitato dall'obsolescenza, è quella verificata numericamente al §5.1.

### A.2 Forma chiusa della soglia di sovranità

Una versione precedente affermava che non esistesse una forma chiusa e riportava la soglia da un'integrazione a 900 mesi. Una forma chiusa esiste. Ponendo stazionario il bacino nell'Eq. 2 si ottiene  $\rho = \kappa(F + Rit)/(1 + \kappa)$ , dunque un'attrito netto di  $(\lambda + \delta)N/(1 + \min(\kappa, \kappa^*))$  e

$$\frac{C_\infty}{C_0} = \frac{R_{int} + R_{disp}}{C_0 (\lambda + \delta)} (1 + \min(\kappa, \kappa^*)) \quad (A.2)$$

che riproduce esattamente i valori integrati. La conseguenza va detta chiaramente perché vincola la lettura di due delle nostre tre soglie. Dove la produzione interna è parametrizzata come frazione di copertura dello stock,  $R_{int} = cov \cdot C_0 (\lambda + \delta)$ , come trattiamo Stati Uniti e Unione Europea in assenza di dati di produzione risolti per giurisdizione, questa collassa in



$$\frac{C_{\infty}}{C_0} = \text{cov} (1 + \min(\kappa, \lambda L)) \quad (\text{A.3})$$

indipendente da  $C_0$ ,  $\lambda$  e  $L$ , con la parentesi limitata in  $[1, 0; 1, 5]$  su tutti i valori considerati. Quelle due soglie sono dunque il riscaldamento di un'assunzione, non una proprietà emergente del modello, e il §7.2 le riporta come mappatura di scenario. La soglia cinese, che deriva da una stima di afflusso assoluto, non è soggetta a questo collasso.

## Appendice B Riproducibilità

Tutti i risultati derivano da un unico script deterministico con seme casuale fissato (20260808). La sua esecuzione rigenera ogni figura, tabella e valore numerico di questo articolo, compresi quelli citati nell'abstract. Il modello consta di 200 righe di NumPy senza dipendenze da solutori esterni. Codice del modello, file dei parametri, output Monte Carlo e registro completo del reperimento delle fonti sono archiviati insieme a questo preprint; si veda *Disponibilità di dati e codice*.

## Disponibilità di dati e codice

Codice del modello, definizioni dei parametri con attribuzione della fonte per ciascun valore, output Monte Carlo, tabelle elaborate e tutto il codice di generazione delle figure sono liberamente disponibili su [github.com/diShine-digital-agency/The-Half-Life-of-Compute](https://github.com/diShine-digital-agency/The-Half-Life-of-Compute) e sono archiviati con il deposito Zenodo di questo articolo. I dati sottostanti sono di terze parti e pubblicamente accessibili: Epoch AI pubblica dati su proprietà e vendite di acceleratori con metodologia documentata; le statistiche di guasto provengono da articoli pubblicati. Non sono stati utilizzati dati proprietari o sotto licenza.

## Dichiarazioni

**Finanziamenti.** La ricerca non ha ricevuto finanziamenti esterni. **Conflitti di interesse.** L'autore è fondatore di diShine, società di consulenza attiva su adozione e governance dell'IA, ed è autore di un volume divulgativo sulla geopolitica della tecnologia citato una sola volta in questo articolo per un contributo di inquadramento. Nessuna delle due relazioni ha influenzato l'analisi, che poggia interamente su dati pubblici e su codice rilasciato. **Assistenza di IA.** Strumenti computazionali sono stati impiegati per il reperimento delle fonti, l'implementazione del modello e la preparazione del manoscritto; tutte le affermazioni analitiche, le scelte di parametrizzazione e le interpretazioni sono dell'autore, e ogni affermazione fattuale è stata verificata su una fonte primaria reperita.

## Nota sulla versione

Questo articolo è la versione italiana di *The Half-Life of Compute: Modelling National AI Capacity Decay Under Supply Severance*. Le due versioni sono generate dal medesimo modello e condividono gli stessi risultati numerici. In caso di discrepanza fa fede la versione inglese, che è quella depositata su Zenodo.

## Bibliografia

- Beaumier, G., et al. (2023). Cross-Network Weaponization in the Semiconductor Supply Chain. *International Studies Quarterly*.
- Cai, J., Fang, Yin, Yu, Wang, Ho & Hu (2026). Managing technological sovereignty: a systematic review of semiconductor industry policy and regional ecosystem governance. *Frontiers in Research Metrics and Analytics*. doi:10.3389/fрма.2026.1762083
- Caravella, S., et al. (2023). Technological sovereignty and strategic dependencies: The case of the photovoltaic supply chain. *Journal of Cleaner Production*.
- Chavez, P., Chilukuri, V. & Scanlon, R. (2026). *Sovereign AI Index*. Center for a New American Security, aprile 2026.

- Cui, L., et al. (2025). Quantitative analysis of the U.S. chip embargo and China's export controls on Ga, Ge and graphite. *Computers & Industrial Engineering*, 7 gennaio 2025. ScienceDirect PII S0360835225000051.
- Dobbie, M. J., et al. (2013). Robustness and sensitivity of weighting and aggregation in constructing composite indices. *Ecological Indicators*.
- Epoch AI (2025). *Hardware failures won't limit AI scaling*. epoch.ai/blog/hardware-failures-wont-limit-ai-scaling
- Epoch AI (2026). *Data on AI Chip Owners e Data on AI Chip Sales*, con metodologia pubblicata. epoch.ai/data
- Epoch AI (2026). *Data on AI Models*: esecuzioni di addestramento di frontiera, fra cui Grok 3 a circa 3e26 FLOP e Grok 4 come la più grande dichiarata. epoch.ai/data/ai-models
- Escoda, K. (2026). *GEOPOLITECH*. Volume III di *The Architecture of the New World: From Code to Matter.*, citato solo per l'inquadramento sui punti di strozzatura.
- Farrell, H. & Newman, A. L. (2019). Weaponized Interdependence: How Global Economic Networks Shape State Coercion. *International Security*, 44(1), 42-79. doi:10.1162/isec\_a\_00351
- Fuller, D. B. (2026). Technology and Economic Statecraft: Weaponizing Technology Export Controls in an Era of Globalized Production. *SSRN Electronic Journal*.
- Grattafiori, A., et al. (2024). The Llama 3 Herd of Models. arXiv:2407.21783.
- Greco, S., Ishizaka, A., Tasiou, M. & Torrisi, G. (2019). On the Methodological Framework of Composite Indices: A Review of the Issues of Weighting, Aggregation, and Robustness. *Social Indicators Research*, 141(1), 61-94. doi:10.1007/s11205-017-1832-9
- Ho, A., Besiroglu, T., Erdil, E., Owen, D., Rahman, R., Guo, Z. C., Atkinson, D., Thompson, N. & Sevilla, J. (2024). Algorithmic Progress in Language Models. arXiv:2403.05812.
- Juniewicz, I. (2026). *Diversion and resale: estimating compute smuggling to China*. Epoch AI, 29 aprile 2026.
- Kelemen, A., et al. (2024). A sensitivity analysis of composite indicators: Min/max thresholds. *Environmental and Sustainability Indicators*.
- Kokolis, A., Kuchnik, M., Hoffman, J., Kumar, A., Malani, P., Ma, F., DeVito, Z., Sengupta, S., Saladi, K. & Wu, C.-J. (2025). Revisiting Reliability in Large-Scale Machine Learning Research Clusters. *IEEE HPCA 2025*. arXiv:2410.21680.
- Leavy, E. (2026). *Machinepower Index 2026*, edizione Q3 2026. machinepowerindex.org
- Lee, J.-D., Choi, S., Kim, K. & Si, S. (2024). *Empirical Measurement of Technology Sovereignty*. IFS Working Paper 2024-01, Institute for Future Strategy, Seoul National University. SSRN 5145685.
- Meng, W. (2025). Modeling the Path of Structural Strategic Deterrence: A Sand Table Simulation Based on Rare Earth Supply Disconnection. arXiv:2505.21579.
- Nardo, M., Saisana, M., Saltelli, A. & Tarantola, S. (2008). *Handbook on Constructing Composite Indicators: Methodology and User Guide*. OCSE / Commissione Europea JRC. JRC47008. ISBN 978-92-64-04346-6.
- Park, D.-J. & Liu, S. (2023). A Study on the Economic Effects of U.S. Export Controls on Semiconductors to China. *Korea International Trade Research Institute*. SSRN 4391187.
- Sherbrooke, C. C. (1968). METRIC: A Multi-Echelon Technique for Recoverable Item Control. *Operations Research*, 16(1), 122-141. doi:10.1287/opre.16.1.122. In precedenza RAND RM-5078.
- Sastry, G., Heim, L., Belfield, H., Anderljung, M., Brundage, M., Hazell, J., O'Keefe, C., Hadfield, G. K., Ngo, R., Pilz, K., Gor, G., Bluemke, E., Shoker, S., Egan, J., Trager, R. F., Avin, S., Weller, A., Bengio, Y. & Coyle, D. (2024). Computing Power and the Governance of Artificial Intelligence. arXiv:2402.08797.
- Shrivastava, M., et al. (2025). China's semiconductor conundrum: understanding US export controls and their efficacy. *Cogent Social Sciences*. doi:10.1080/23311886.2025.2528450
- Yew, R.-J., Creasey, K. E., Curtis, T. L. & Venkatasubramanian, S. (2026). The Commodification of AI Sovereignty: Lessons from the Fight for Sovereign Oil. arXiv:2601.11763.